



Universidad de Oviedo

Facultad de Ciencias

UNIVERSIDAD DE OVIEDO

Facultad de Ciencias

Grado en Matemáticas

Relación del tabaquismo y el género con el IMC y la edad de introducción al tabaquismo

TRABAJO DE INFERENCIA ESTADÍSTICA

30 de Marzo de 2026

Grupo α :

Mateo Rama García

Javier Ortín Rodenas

Jorge Gota Ortín

Alejandra Sánchez Mayo

Pablo Hernández Hernández

Índice

1. Resumen	2
2. Introducción	2
3. Material y Métodos	3
3.1. Depuración de datos	3
3.1.1. Depuración de los datos para el análisis del IMC	3
3.1.2. Depuración de la variable sobre la edad de inicio al tabaquismo . . .	3
3.2. Métodos estadísticos utilizados	4
3.2.1. Métodos estadísticos del objetivo 1	4
3.2.2. Métodos estadísticos objetivo 2	4
3.3. Justificación de las técnicas empleadas	5
3.3.1. Justificación de las técnicas empleadas para el objetivo 1	5
3.3.2. Justificación de técnicas empleadas para el objetivo 2	5
4. Resultados	6
4.1. Resultados del objetivo 1: Estudio del IMC según tabaquismo	6
4.2. Resultados del Objetivo 2: Análisis de la edad de inicio por género	10
5. Discusión	12
6. Conclusiones	12
7. Contribución de los autores	13
8. Bibliografía	13
A. ANOVA de Welch	14
A.1. Resultados previos	14
A.1.1. Esperanza de la forma cuadrática	14
A.1.2. Ley de la esperanza total	14
A.1.3. Ley de la varianza total	14
A.1.4. Forma cuadrática como χ_r^2	15
A.2. Estadísticos del ANOVA de Welch	15
A.2.1. F de Welch	16
A.2.2. Contrastes por parejas (t de Welch)	17
B. Relación matemática entre la distribución Lognormal y la Normal	18
C. Código fuente y datos	19

1. Resumen

Este trabajo presenta un análisis de inferencia estadística basado en los microdatos de la Encuesta Nacional de Salud de España (ENSE) 2023, con el fin de estudiar el impacto del tabaquismo en variables biométricas y demográficas de la población adulta.

Objetivos: Se plantean dos objetivos principales:

- Evaluar la relación entre los hábitos de consumo de tabaco y el Índice de Masa Corporal (IMC) diferenciando por sexo.
- Comparar la edad de inicio en el hábito tabáquico entre hombres y mujeres para identificar patrones de comportamiento diferencial.

Metodología: Tras un proceso de filtrado y cálculo numérico del IMC, se emplearon técnicas descriptivas (histogramas y gráficas Q-Q) y de inferencia paramétrica. Para el análisis del IMC, se validó la homocedasticidad mediante el test de Levene, optando por un modelo ANOVA tradicional para el grupo de hombres y un ANOVA de Welch para el de mujeres debido a la heterocedasticidad detectada. Para la edad de inicio, se determinó mediante la librería `fitdistrplus` que el modelo Lognormal era el de mejor ajuste. Tras una transformación logarítmica para garantizar normalidad, se aplicó una prueba t de Welch y se interpretaron los resultados mediante la media geométrica. Aunque no formase parte de nuestros objetivos iniciales, descubrimos que el IMC presenta varianzas mucho mayores en los subgrupos de mujeres (a excepción de las fumadoras ocasionales).

Resultados principales: Los resultados revelan diferencias estadísticamente significativas ($p < 0.05$) en el IMC según el hábito tabáquico en ambos sexos, destacando el grupo de exfumadores por presentar valores distintos al resto. En cuanto a la edad de inicio, se halló que los hombres comienzan a fumar significativamente antes que las mujeres, con una media geométrica de 17.00 años frente a los 17.96 años del grupo femenino ($p < 0.05$).

Conclusiones relevantes: Se concluye que el tabaquismo está vinculado a variaciones en el IMC, aunque la magnitud de la diferencia sugiere prudencia en su relevancia clínica. Asimismo, la edad de inicio en el consumo de tabaco es un fenómeno asimétrico que ocurre mayoritariamente en la adolescencia, evidenciando que las mujeres retrasan su incorporación al hábito aproximadamente un año respecto a los hombres. Estos hallazgos subrayan la necesidad de políticas de prevención temprana teniendo en cuenta el género.

2. Introducción

El tabaco es una sustancia que actúa como agente mutágeno en nuestro organismo. Por tanto, buscamos ver cómo afecta el consumo de tabaco a variables biométricas recogidas en la encuesta de salud nacional para adultos de 2023; en concreto, cómo se relaciona con el IMC y el género. Además, buscamos ver la percepción y el impacto social del tabaco al estudiar la edad de inicio entre fumadores.

Se pretende analizar de manera rigurosa datos reales para estudiar los efectos del tabaquismo. Por un lado, el estudio del IMC estudia su efecto sobre la salud, mientras que la edad de introducción al tabaquismo está marcada por las tendencias de consumo y la percepción social del tabaco, avalando así la importancia del estudio.

Además, debido a la naturaleza de los datos recogidos, el estudio no solo distingue entre personas que fuman o no, sino que podemos discernir con más detalle al contar con los siguientes tipos de respuesta: “fumador diario”, “fumador ocasional”, “exfumador” o “nunca ha fumado”.

Para este estudio se utilizó el conjunto de datos de la Encuesta Nacional de Salud de Adultos ([ENSE](#)) de 2023. El objetivo general es analizar, mediante técnicas de inferencia estadística, la relación entre el consumo de tabaco, el sexo y el Índice de Masa Corporal (IMC), así como evaluar la edad de inicio en el tabaquismo dentro de la población adulta.

Para alcanzar este propósito, se plantean los siguientes objetivos específicos:

1. Analizar el impacto del tabaquismo en el IMC entre hombres y entre mujeres.
2. Comparar la edad de introducción al tabaquismo entre hombres y mujeres.

3. Material y Métodos

3.1. Depuración de datos

Debido al proceso de toma de respuestas de la [ENSE](#) 2023, las variables del conjunto de datos vienen codificadas con nombres y valores que no son operativos para su análisis. En primer lugar, establecimos una codificación más manejable para facilitar el estudio de los datos.

3.1.1. Depuración de los datos para el análisis del IMC

Los datos originales cuentan ya con una variable *IMC*, pero es cualitativa y no otorga mucha información. Al contar también con variables cuantitativas de peso y altura, optamos por calcular el IMC de manera numérica para hacer un estudio más a fondo. Para ello, filtramos el conjunto de datos para trabajar únicamente con aquellos individuos que hayan respondido sobre su altura y sobre su peso, y calcular así su IMC.

3.1.2. Depuración de la variable sobre la edad de inicio al tabaquismo

Debido a que la encuesta de la [ENSE](#) 2023 únicamente registra la edad de inicio para las personas que consumen tabaco diariamente, el análisis requirió una adaptación previa. En primer lugar, se restringió la muestra de estudio exclusivamente al grupo de fumadores a diario. Posteriormente, se procedió a depurar la variable *Edad de inicio* dentro de dicha submuestra, eliminando aquellos individuos que no dieron datos al respecto cuando fueron

encuestados.

3.2. Métodos estadísticos utilizados

3.2.1. Métodos estadísticos del objetivo 1

En primer lugar, graficamos la distribución empírica de los datos para obtener una idea inicial de qué posibles distribuciones pueden seguir. En particular, comparamos la distribución empírica con una distribución gaussiana teórica $\mathcal{N}(\mu, \sigma^2)$. Además de estudiar el comportamiento de la muestra en su totalidad, analizamos la gaussianidad de los distintos subgrupos según hábitos de tabaquismo y género usando gráficas de histograma-densidad teórica y gráficas cuantil-cuantil.

Al haber una clara distinción entre factor (tabaquismo) y variable respuesta (IMC) con cierta gaussianidad, nos preguntamos si estamos bajo las condiciones de aplicar ANOVA. Por tanto, estudiamos las diferencias de varianzas entre grupos por tabaquismo y género. Para ello, utilizamos el test de Levene y diagramas de cajas. Concluimos que los hombres presentaban homocedasticidad, pero las mujeres no.

Por todo lo anterior, llevamos a cabo un análisis de varianza tradicional para los hombres, y un ANOVA de Welch (no asume homocedasticidad) para las mujeres. Al haberse detectado desigualdad de medias, fue necesario hacer contrastes a posteriori en ambos casos.

3.2.2. Métodos estadísticos objetivo 2

Para el análisis de la edad de inicio al tabaquismo, se evaluó el ajuste empírico de la muestra frente a una selección de modelos tanto continuos (Weibull, Gamma, Normal y Lognormal) como discretos (Poisson y Binomial Negativa) utilizando la librería `fitdistrplus` de R. Este procedimiento se realizó de forma independiente para hombres y mujeres, validando el ajuste mediante la superposición gráfica de las funciones de densidad y masa sobre los histogramas. Cabe destacar que, aunque la edad se registre de forma discreta en años cumplidos, su tratamiento como variable continua se justifica debido a que el inicio del hábito tabáquico es un proceso que ocurre en un continuo temporal y el uso de modelos continuos permite una mayor flexibilidad para capturar con precisión la marcada asimetría positiva y el pico de incidencia en la adolescencia que presentan los datos.

En cuanto a la inferencia, se aplicó una transformación logarítmica natural ($Y = \ln(X)$) sobre la variable original. Posteriormente, se realizó un contraste de homocedasticidad mediante el Test de Levene y, tras detectarse varianzas significativamente distintas, se utilizó la prueba t de Welch para comparar las medias de los logaritmos entre ambos géneros. Finalmente, se deshizo la transformación de la variable para interpretar los resultados en el contexto original (edad en años).

3.3. Justificación de las técnicas empleadas

3.3.1. Justificación de las técnicas empleadas para el objetivo 1

En primer lugar, las comparaciones de la distribución empírica con la teórica $\mathcal{N}(\mu, \sigma^2)$ se llevaron a cabo usando la mediana y la varianza muestral como estimadores de μ y de σ^2 , respectivamente. Puesto que la distribución empírica presentaba cierta asimetría por la derecha, la mediana es un estimador más robusto en estas circunstancias. Además, la varianza muestral es el EMV de σ^2 y es asintóticamente insesgado. Por tanto, presenta propiedades preferibles a la cuasivarianza al tratar con tamaños muestrales elevados.

Los test de bondad de ajuste suelen rechazar H_0 cuando se llevan a cabo sobre muestras de gran tamaño. Por tanto, recurrimos a la estadística descriptiva para comprobar el ajuste de la distribución a una gaussiana teórica.

Al presentar algo de asimetría por la derecha, no usamos el test de Bartlett sobre nuestra muestra. En su lugar, utilizamos el test de Levene, que no es tan dependiente de estar en el modelo paramétrico. Puesto que los tamaños muestrales de nuestro conjunto de datos eran elevados, nos apoyamos también en técnicas descriptivas, ya que los tests de hipótesis pueden dar lugar a rechazos artificiales en estas condiciones: generan p-valores estadísticamente significativos que no suponen un impacto en la práctica.

La independencia entre subgrupos necesaria para aplicar ANOVA viene dada por la fiabilidad de los datos y la metodología de muestreo usada para recopilarlos. Los grupos de hombres presentaban varianzas similares entre sí, por lo que aplicamos un ANOVA tradicional. En cambio, los grupos de mujeres presentan tamaños y varianzas desequilibrados, por lo que el ANOVA de Welch es preferible en este caso. En ambos análisis de varianza, tuvimos que recurrir a contrastes por parejas a posteriori, que comparamos con diagramas de cajas (de nuevo, los contrastes pueden producir rechazos artificiales para muestras grandes). Usamos contrastes por recorrido estudentizado (**TukeyHSD** en R) para los hombres, y test t de Welch (explicado en [Apéndice A](#)) para las mujeres.

Antes de decantarnos por el ANOVA de Welch, intentamos reestructurar los grupos de tabaquismo en mujeres con el fin de obtener varianzas similares entre los nuevos grupos y aplicar ANOVA tradicional sobre ellos. Por ejemplo, agrupar “Fumador diario” y “Fumador ocasional” en una nueva categoría “Fumador” (y otras combinaciones). No obstante, ninguna combinación intuitiva cumplió los requisitos.

3.3.2. Justificación de técnicas empleadas para el objetivo 2

Para el análisis de la edad de inicio al tabaquismo, se evaluó el ajuste de la muestra frente a modelos tanto discretos (Poisson y Binomial Negativa) como continuos (Weibull, Gamma, Lognormal y Normal). Dado que la variable se registra en años cumplidos (valores enteros), se consideró pertinente explorar distribuciones discretas, si bien la elección de las familias Weibull, Gamma y Lognormal se fundamenta en que la edad de inicio es una variable estrictamente positiva con una marcada asimetría hacia la derecha, característica de los “tiempos de espera” hasta un evento. A pesar de que la distribución Normal resultaba

teóricamente inadecuada por su soporte negativo, se mantuvo en la comparativa dado que es el modelo de referencia en el que se basan la mayoría de los tests paramétricos clásicos

Con el fin de poder aplicar contrastes paramétricos, que exigen que los datos se distribuyan de forma aproximadamente normal, se aplicó una transformación logarítmica sobre la variable original. Esta transformación está teóricamente fundamentada: si la variable sigue una distribución lognormal, su logaritmo sigue exactamente una distribución normal. La justificación teórica de esta transformación se encuentra en [Apéndice B](#).

Una vez transformados los datos, antes de comparar las medias entre géneros, fue necesario verificar si las varianzas de ambos grupos podían considerarse iguales y para ello se empleó el test de Levene. Al rechazarse la igualdad de varianzas, se descartó el uso de la prueba t clásica y se optó por la prueba t de Welch, que corrige los grados de libertad en función de las varianzas muestrales observadas, garantizando así la validez del contraste sin necesidad de asumir homocedasticidad.

Finalmente, dado que los resultados del contraste se obtienen en escala logarítmica, fue necesario trasladarlos a la escala original de años para facilitar su interpretación. Con este fin se utilizó la media geométrica, que es el estimador natural de la tendencia central en distribuciones lognormales. A diferencia de la media aritmética, no se ve distorsionada por los valores extremos de la cola derecha, lo que la convierte en una medida más representativa del comportamiento típico de la población.

4. Resultados

4.1. Resultados del objetivo 1: Estudio del IMC según tabaquismo

Estas fueron las gráficas de ajuste a distribuciones gaussianas según el género y los hábitos de tabaquismo, comparando la densidad empírica con la de una gaussiana estimada para cada caso.




Figura 1: Distribución del IMC por subgrupos

De manera similar, estas fueron las gráficas cuantil-cuantil asociadas:




Figura 2: Gráficas cuantil-cuantil por subgrupos

Podemos apreciar como las distribuciones presentan asimetría por la derecha, pero poseen gaussianidad marcada en el resto de cuantiles.

Atendiendo ahora a la estadística descriptiva entre grupos:

Tabla 1: Estadísticos del IMC según género y tabaquismo

Género	Tabaquismo	Varianza	Media	Mediana	n
Hombre	Nunca ha fumado	15.55029	26.06619	25.66115	4354
Hombre	Exfumador	15.22488	27.36678	26.86927	2754
Hombre	Fumador diario	14.73462	26.26433	25.92593	1976
Hombre	Fumador ocasional	13.57848	26.03203	25.82645	262
Mujer	Nunca ha fumado	21.24381	25.58005	24.97399	6922
Mujer	Exfumador	25.28869	26.11291	25.34435	1991
Mujer	Fumador diario	20.10343	25.03555	24.34176	1491
Mujer	Fumador ocasional	16.06483	24.72695	24.14152	221

Podemos notar una clara diferencia entre grupos de hombres y mujeres. Los hombres tienen varianzas grupales menores, y más homogéneas entre sí. Las mujeres, en cambio, presentan varianzas más dispares y más altas (salvo las fumadoras ocasionales).

Para confirmar estas dispersiones, se realiza un test de Levene:

```
## [1] "p-valor para los hombres: 0.538223684953325"
## [1] "p-valor para las mujeres: 0.000434705587775402"
```

Para comparar aún más las dispersiones, recurrimos a diagramas de cajas:




Figura 3: Diagramas de cajas por grupos de tabaquismo según género

Podemos por tanto concluir que los hombres presentan homocedasticidad mientras que las mujeres presentan heterocedasticidad. En primer lugar, se aplica ANOVA al subgrupo de hombres:

```
##               Df Sum Sq Mean Sq F value Pr(>F)
## Fuma           3   3055  1018.3    66.84 <2e-16 ***
## Residuals    9342 142308     15.2
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Como $p < \alpha = 0.05$, se rechaza la hipótesis nula de igualdad de medias y se concluye que en el subgrupo de hombres, dependiendo del hábito tabáquico, el promedio de IMC varía. Veamos cuáles de estos hábitos tabáquicos provocan diferencias estadísticamente significativas haciendo uso de contrastes a posteriori:




Figura 4: Contrastes por parejas a posteriori entre subgrupos de hombres

Las diferencias significativas se observan cuando se comparan los exfumadores con el resto de grupos. Realizamos diagramas de cajas para asegurarnos de estos resultados:




Figura 5: Diagramas de cajas por parejas para grupos de hombres

Para el caso de subgrupo de mujeres, no se cumple la hipótesis de homocedasticidad de ANOVA clásico y optamos por usar ANOVA de Welch, que no requiere esta suposición:

```
## One-way analysis of means (not assuming equal variances)
## data: IMC and Fuma
## F = 18.001, num df = 3.00, denom df = 970.58, p-value = 2.252e-11
```

De nuevo, como $p < \alpha = 0.05$, se rechaza la hipótesis nula de igualdad de medias. Se concluye que en el subgrupo de mujeres la media del IMC depende del tabaquismo. Veamos qué parejas de hábitos tabáquicos presentan diferencias estadísticamente significativas haciendo uso de contrastes a posteriori:

```
## Pairwise comparisons using t tests with non-pooled SD
## data: datos1$IMC and datos1$Fuma
##
## Fumador diario Fumador ocasional Exfumador
## Fumador ocasional 0.69 - -
## Exfumador < 2e-16 1.9e-12 -
## Nunca ha fumado 1.00 0.41 < 2e-16
## P value adjustment method: bonferroni
```

En este caso, las diferencias más claras se observan en el caso de exfumadoras, donde su IMC difiere estadísticamente del IMC de las fumadoras diarias, al de las ocasionales y al de las que nunca han fumado.




Figura 6: Contrastes por parejas a posteriori entre subgrupos de mujeres

4.2. Resultados del Objetivo 2: Análisis de la edad de inicio por género

Como paso previo a la inferencia, se estudió la muestra mediante estadísticos de tendencia central y dispersión (Tabla 2). Los datos indican que, en promedio, las mujeres inician el consumo de tabaco a una edad superior a la de los hombres.

Tabla 2: Estadísticos descriptivos de la edad de inicio al tabaquismo por género.

Género	n	Media	Mediana	D. Típica	Mínimo	Máximo
Hombre	1958	17.42	17.00	4.43	6	65
Mujer	1478	18.59	18.00	5.89	9	66

El análisis de las medianas reafirma esta observación. Por su parte, la mayor desviación típica registrada en el grupo femenino revela una mayor dispersión en la edad de inicio al consumo.

Se comparó la distribución empírica de los datos con distribuciones teóricas ajustadas, tanto continuas como discretas. Para ello, usamos el paquete `fitdistrplus` de R.




Figura 7: Comparación de la distribución empírica con modelos teóricos

El modelo Lognormal proporciona el mejor ajuste a los datos observados para ambos sexos.

Esta distribución logra capturar con precisión el pico de iniciación durante la adolescencia, además de presentar una larga cola derecha que modela los inicios más tardíos.

Dado el carácter lognormal de la variable, la inferencia se realizó sobre la transformación logarítmica de la edad para satisfacer el supuesto de normalidad exigido por los test paramétricos. Los detalles técnicos y el código de esta transformación se encuentran debidamente detallados en el [Apéndice B](#).

Mediante la comparación gráfica con la función de densidad teórica ([Figura 8](#)), se comprobó cómo la transformación logarítmica aproxima la distribución empírica a una curva normal teórica.




Figura 8: Ajuste de la distribución transformada a una normal.

La transformación logarítmica ha permitido que la distribución empírica de la edad de inicio se aproxime razonablemente a la curva normal teórica en ambos géneros, permitiéndonos aplicar pruebas paramétricas. A continuación, procedemos a evaluar la igualdad de varianzas entre sexos mediante el Test de Levene.

Tabla 3: Resultado del Test de Levene para la igualdad de varianzas.

Variable	Estadístico F	gl	p-valor
Log(Edad inicio)	9.9965	1	0.0016

El rechazo de la hipótesis nula de homocedasticidad ($p < 0.05$) confirmó que las varianzas poblacionales de los grupos son distintas. En consecuencia, se aplicó la prueba t de Welch para comparar las medias logarítmicas de ambos géneros ([Tabla 4](#)).

Tabla 4: Resultados del contraste de medias mediante la prueba t de Welch.

Comparación	Estadístico t	gl	p-valor	I.C. 95 %
Hombre vs. Mujer	-6.9377	2923.5	<0.001	[-0.070, -0.039]

De nuevo como el $p < 0.05$, se rechaza la hipótesis nula de igualdad de medias y se puede concluir que existen diferencias en el promedio de edad de inicio al tabaquismo entre hombres y mujeres.

Dada la asimetría positiva de los datos originales, la comparación final se ha basado en la media geométrica, ya que resulta más adecuada en presencia de valores atípicos más elevados.

Tabla 5: Comparativa final de la edad de inicio (Media Geométrica por Género).

Género	Media Logarítmica	Media Geométrica (Años)
Hombre	2.833	17.00
Mujer	2.888	17.96

Los resultados confirman que la edad típica de inicio en hombres es inferior a la de las mujeres, existiendo una diferencia significativa de casi un año en la incorporación al hábito tabáquico entre ambos sexos.

5. Discusión

Los resultados obtenidos muestran la existencia de diferencias estadísticamente significativas tanto en el IMC según el hábito tabáquico como en la edad de inicio entre hombres y mujeres. Sin embargo, estas diferencias son relativamente pequeñas, por lo que su relevancia práctica debe interpretarse con cautela, especialmente considerando el gran tamaño muestral.

Desde el punto de vista descriptivo, ambas variables presentan asimetría positiva y valores atípicos, lo que ha justificado el uso de métodos robustos y, en particular, del ANOVA de Welch cuando no se cumple la homocedasticidad.

En cuanto a la edad de inicio, se observa que la mayoría de los individuos comienza a fumar en la adolescencia, siendo este resultado coherente con estudios previos. Las mujeres tienden a iniciarse ligeramente más tarde, aunque la diferencia no es muy acusada.

Estos resultados refuerzan la importancia de centrar las estrategias de prevención en edades tempranas y considerar posibles diferencias por género.

6. Conclusiones

Del análisis inferencial llevado a cabo, se derivan las siguientes conclusiones:

1. La distribución del Índice de Masa Corporal (IMC) presenta diferencias significativas en función de la combinación del género y el hábito de consumo de tabaco, no pudiendo asumirse igualdad de varianzas entre los distintos subgrupos poblacionales.

2. Existencia de mayor dispersión en el IMC de las mujeres frente al de los hombres. Aunque no era un objetivo inicial, este hallazgo refleja una mayor variedad en el grupo femenino.
3. La edad de inicio en el consumo de tabaco no presenta un comportamiento normal, siendo la familia de distribuciones lognormales la que mejor modela este fenómeno demográfico.
4. Existen diferencias estadísticamente significativas en la edad de introducción al tabaquismo según el género, evidenciando que, a nivel poblacional, las mujeres tienden a iniciarse en el hábito a una edad ligeramente superior a la de los hombres.

7. Contribución de los autores

- **Mateo Rama García:** Redacción de la memoria, análisis de la influencia del género en la edad de inicio del tabaquismo y colaborador en el análisis de la influencia del tabaquismo sobre el IMC.
- **Javier Ortín Rodenas:** Búsqueda y depuración del conjunto de datos. Análisis de la influencia del tabaquismo sobre el IMC.
- **Jorge Gota Ortín:** Análisis descriptivo gráfico, ajuste de distribuciones paramétricas y redacción del análisis de la edad de inicio al tabaquismo.
- **Alejandra Sánchez Mayo:** Ejecución de los contrastes de hipótesis para el IMC (ANOVA y pruebas post-hoc). Redacción de la memoria.
- **Pablo Hernández Hernández:** Realización de la presentación, estructuración del informe y verificación de homocedasticidad.

8. Bibliografía

Referencias

- Delignette-Muller, M. L., & Dutang, C. (2015). fitdistrplus: An R Package for Fitting Distributions. *Journal of Statistical Software*, 64(4), 1-34. <https://cran.r-project.org/web/packages/fitdistrplus/fitdistrplus.pdf>
- Ministerio de Sanidad. (2023). Encuesta Nacional de Salud de España (ENSE). <https://www.sanidad.gob.es/estadEstudios/estadisticas/encuestaSaludEspana/home.htm>

A. ANOVA de Welch

A.1. Resultados previos

Consideramos $\vec{x}$ un vector normal n -dimensional de variables independientes donde:

$$x_{i,j} \sim N(\mu_i, \sigma_i^2) \quad \forall i \in \{1, \dots, q\} \quad \forall j \in \{1, \dots, n_i\}$$

Al ser independientes, $\vec{x} \sim \mathcal{N}_n(\vec{\mu}, \Sigma)$, con $\Sigma = \text{diag}(\sigma_1^2 I_{n_1} \dots, \sigma_q^2 I_{n_q})$.

A.1.1. Esperanza de la forma cuadrática

Sea $A \in \mathcal{M}_n(\mathbb{R})$ una matriz no aleatoria,

$$\begin{aligned} E[\vec{x}^t A \vec{x}] &= E[\text{tr}(\vec{x}^t A \vec{x})] = E[\text{tr}\{A \vec{x} \vec{x}^t\}] = \text{tr}(A E[\vec{x} \vec{x}^t]) = \text{tr}(A(\Sigma + \vec{\mu} \vec{\mu}^t)) = \\ &= \text{tr}(A \Sigma) + \text{tr}(\vec{\mu}^t A \vec{\mu}) = \text{tr}(A \Sigma) + \vec{\mu}^t A \vec{\mu} \end{aligned}$$

A.1.2. Ley de la esperanza total

Sea X una variable aleatoria y Y un vector aleatorio definido en el mismo espacio de probabilidad,

$$\begin{aligned} E[E[X|Y]] &= \int_{\mathbb{R}} E[X|Y=y] f_Y(y) dy = \int_{\mathbb{R}} \left(\int_{\mathbb{R}} x f_{X|Y}(x|y) dx \right) f_Y(y) dy = \\ &= \int_{\mathbb{R}} \int_{\mathbb{R}} x \frac{f_{X,Y}(x,y)}{f_Y(y)} f_Y(y) dx dy = \int_{\mathbb{R}} x \left(\int_{\mathbb{R}} f_{X,Y}(x,y) dy \right) dx = \\ &= \int_{\mathbb{R}} x f_X(x) dx = E[X] \end{aligned}$$

A.1.3. Ley de la varianza total

$$\begin{aligned} E[\text{Var}(X|Y)] + \text{Var}(E[X|Y]) &= \\ &= E[E[X^2|Y] - (E[X|Y])^2] + \left(E[(E[X|Y])^2] - (E[E[X|Y]])^2 \right) = \\ &= \left(E[E[X^2|Y]] - E[(E[X|Y])^2] \right) + \left(E[(E[X|Y])^2] - (E[X])^2 \right) = \\ &= E[X^2] - E[(E[X|Y])^2] + E[(E[X|Y])^2] - (E[X])^2 = \\ &= E[X^2] - (E[X])^2 = \\ &= \text{Var}(X). \end{aligned}$$

A.1.4. Forma cuadrática como χ_r^2

Sea $A \in \mathcal{M}_n(\mathbb{R})$ una matriz simétrica de rango r tal que $A\Sigma$ es simétrica e idempotente, si $A\vec{\mu} = 0$; entonces, $\vec{x}^t A \vec{x} \stackrel{H_0}{=} \chi_r^2$.

Demostración:

Por hipótesis, como $A\vec{\mu} = 0$ y es simétrica, tenemos:

$$(\vec{x}^t - \vec{\mu}^t) A (\vec{x} - \vec{\mu}) = \vec{x}^t A \vec{x} - \vec{\mu}^t A \vec{x} + \vec{x}^t A \vec{\mu} + \vec{x}^t A \vec{x} = \vec{x}^t A \vec{x}$$

Al ser $\Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$ definida positiva, la siguiente matriz está bien definida:

$$\Sigma^{-1/2} := \text{diag}(\sigma_1^{-1/2}, \dots, \sigma_n^{-1/2})$$

Bajo H_0 , todos los niveles de factor tienen la misma media poblacional, luego el siguiente cambio de variable nos permite tipificar:

$$\vec{u} := \Sigma^{-1/2}(\vec{x} - \vec{\mu}) \sim \mathcal{N}_n(0, I_n)$$

Veamos cómo expresar la forma cuadrática para este nuevo cambio de variable:

$$\vec{x}^t A \vec{x} = (\vec{x}^t - \vec{\mu}^t) A (\vec{x} - \vec{\mu}) = (\Sigma^{1/2} \vec{u})^t A (\Sigma^{1/2} \vec{u}) = \vec{u}^t (\Sigma^{1/2} A \Sigma^{1/2}) \vec{u}$$

Donde $\Sigma^{1/2} = (\Sigma^{-1/2})^{-1}$. Por simplicidad, denotaremos $B := \Sigma^{1/2} A \Sigma^{1/2}$.

Tal y como hemos visto en teoría (versión ANOVA tradicional), sabemos que dado un vector $\vec{y} \sim \mathcal{N}_n(\vec{\nu}, \sigma I_n)$ y una matriz simétrica e idempotente M de rango r que cumple $M\vec{\nu} = 0$; entonces, $\vec{y}^t A \vec{y} \sim \sigma \chi_r^2$. Veamos que B es simétrica e idempotente para aplicar este resultado al vector $\vec{u}$ anterior.

$$B^t = (\Sigma^{1/2} A \Sigma^{1/2})^t = \Sigma^{1/2^t} A^t \Sigma^{1/2^t} = \Sigma^{1/2} A \Sigma^{1/2} = B$$

$$BB = (\Sigma^{1/2} A \Sigma^{1/2})(\Sigma^{1/2} A \Sigma^{1/2}) = \Sigma^{1/2} A \Sigma A \Sigma^{1/2} \iff A \Sigma A = A \iff A \Sigma A \Sigma = A \Sigma$$

La equivalencia se deduce de multiplicar ambos lados por $\Sigma^{-1/2}$ por la izquierda y por la derecha. Como $A\Sigma$ es idempotente por hipótesis, concluimos que B es idempotente. Así, aplicando el resultado citado:

$$\vec{x}^t A \vec{x} = \vec{u}^t B \vec{u} \sim \chi_r^2$$

A.2. Estadísticos del ANOVA de Welch

En esta sección trabajaremos con el vector de medias por niveles de factor, en lugar de con la muestra al completo:

$$\vec{x} = N_q(\vec{\mu}, \Sigma) \quad \text{con } \Sigma = \text{diag}(\sigma_1^2/n_1, \dots, \sigma_q^2/n_q)$$

A.2.1. F de Welch

En lugar del *SCF* tradicional, el ANOVA de Welch parte del siguiente estadístico, que irá corrigiendo:

$$Q_1 := \sum_{i=1}^q w_i (\bar{x}_i - \bar{x}_w)^2 \quad \text{donde } w_i = \frac{n_i}{\sigma_i^2}, \bar{x}_w = \frac{\sum w_i \bar{x}_i}{\sum w_i}$$

Podemos expresar este estadístico como una forma cuadrática asociada a la siguiente matriz:

$$M = W - \frac{1}{\sum_{i=1}^q w_i} \vec{w} \vec{w}^t \quad \text{con } W = \text{diag}(w_1, \dots, w_q) = \Sigma^{-1}$$

Esta matriz es simétrica, y bajo H_0 cumple $M\vec{\mu} = 0$, pues $M\vec{1} = 0$ y $\vec{\mu} \stackrel{H_0}{=} \mu \cdot \vec{1}$. Además, $M\Sigma$ es idempotente:

$$\begin{aligned} M\Sigma &= W\Sigma - \frac{1}{\vec{1}^t \vec{w}} \vec{w} \vec{w}^t \Sigma = I_q - \frac{1}{\vec{1}^t \vec{w}} \vec{w} (W\vec{1})^t \Sigma = I_q - \frac{1}{\vec{1}^t \vec{w}} (\vec{w} \vec{1}^t) W \Sigma = \\ &= I_q - \frac{1}{\vec{1}^t \vec{w}} (\vec{w} \vec{1}^t) = I_q - \frac{\vec{w} \vec{1}^t}{\vec{1}^t \vec{w}} = I_q - P \end{aligned}$$

El término que resta, P , es un proyector:

$$PP = \frac{(\vec{w} \vec{1}^t)(\vec{w} \vec{1}^t)}{(\vec{1}^t \vec{w})^2} = \frac{\vec{w} (\vec{1}^t \vec{w}) \vec{1}^t}{(\vec{1}^t \vec{w})^2} = \frac{\vec{w} \vec{1}^t}{\vec{1}^t \vec{w}} = P$$

De este modo, $(M\Sigma)(M\Sigma) = I_q^2 - 2I_q P + P^2 = I_q - P = M\Sigma$.

Por tanto, su forma cuadrática Q_1 seguirá una distribución χ_{q-1}^2 , según el rango de M . No obstante, como las σ_i son desconocidas, se trabaja en la práctica con $\hat{w}_i := n_i/s_i^2$. Este nuevo estadístico ya no sigue una distribución χ^2 perfecta al haber sustituido σ_i por s_i . Para cuantificar qué tan distinto es, estudiemos sus momentos.

Sea Q la nueva forma cuadrática asociada a la nueva matriz $\hat{M}$, la aleatoriedad de $\hat{M}$ depende solo de las s_i . Aplicaremos la fórmula de la esperanza total para hallar el primer momento. Así, fijados estos parámetros, tenemos que: $E[Q|\vec{s}] = \text{tr}(\hat{M}\Sigma) + \vec{\mu}^t \hat{M} \vec{\mu} \stackrel{H_0}{=} \text{tr}(\hat{M}\Sigma)$. En estas condiciones, la traza viene dada por:

$$\text{tr}(\hat{W}\Sigma) - \text{tr}\left(\frac{1}{\sum_i \hat{w}_i} \vec{\hat{w}} \vec{\hat{w}}^t \Sigma\right) = \sum_{i=1}^q \frac{\sigma_i^2}{n_i} \cdot \frac{n_i}{s_i^2} - \frac{1}{\sum_i \hat{w}_i} \sum_{i=1}^q \frac{\sigma_i^2}{n_i} \hat{w}_i^2 = \sum_{i=1}^q \frac{\sigma_i^2}{s_i^2} \left(1 - \frac{\hat{w}_i}{\sum_i \hat{w}_i}\right)$$

A partir de esta expresión, podemos hacer un desarrollo de Taylor centrado en $\vec{\sigma} = (\sigma_1^2/n_1, \dots, \sigma_q^2/n_q)$. Tomando esperanzas la expansión de Taylor podemos hallar la esperanza de Q , que (tras un extenso desarrollo) se aproxima por:

$$E[Q] \approx (q-1) \left[1 + \frac{2(q-2)}{q^2-1} \Lambda\right] \quad \text{Donde } \Lambda = \sum_{i=1}^q \frac{1}{n_i-1} \left(1 - \frac{w_i}{\sum w_k}\right)^2$$

La definición de Λ depende de w_i , pero en la práctica es aproximada de nuevo por los $\hat{w}_i$. Esto no supone un problema, pues al ser s_i^2 el EMV de σ_i^2 es fuertemente consistente.

Aplicando el Teorema de Slutsky, $\hat{w}_i \xrightarrow{P} w_i$ luego $\hat{\Lambda}$ converge a Λ .

Para el segundo momento, usaremos un razonamiento similar al anterior. Emplearemos la fórmula de la varianza total condicionando de nuevo por las s_i . Por tanto, $Var Q = E[Var(Q|\vec{s})] + Var(E[Q|\vec{s}])$. Comencemos comprobando el primer sumando.

Como s_i^2 es el EMV de σ_i^2/n_i y se cumplen las condiciones de regularidad, es asintóticamente fuertemente consistente. Por tanto, para n_i suficientemente grande $\forall i \in \{1, \dots, q\}$, tenemos:

$$E[Var(Q|\vec{s})] \approx Var(Q|\sigma) = Var(\chi_{q-1}^2) = 2(q-1)$$

Estudiemos ahora el segundo sumando. Al estudiar antes $E[Q]$, pudimos deducir que $E[Q|\vec{s}] \stackrel{H_0}{=} tr(\hat{M}\Sigma)$. Para hallar la varianza de esta expresión, podemos hacer una expansión de Taylor centrada en $\vec{s} = \vec{\sigma}$. Tras otro extenso desarrollo algebraico, se puede concluir que $Var(E[Q|\vec{s}]) \approx 2\Lambda$. Así, $Var(Q) \approx 2(q-1) + 2\Lambda$.

El estadístico final F de Welch se define como:

$$F_W := \frac{Q/(q-1)}{C} \quad \text{Donde } C = 1 + \frac{2(q-2)}{q^2-1}\Lambda$$

Comparando con los momentos de Q , podemos ver que $E[F_W] \approx 1$, que refleja el comportamiento de una F_{q-1, v_2} para v_2 suficientemente grande. Buscamos que F_W se comporte como una F_{q-1, v_2} para cierto valor v_2 . Comparando con los momentos de una distribución F_{q-1, v_2} y despejando, concluimos:

$$\nu_2 = \frac{q^2-1}{3\Lambda} \Rightarrow Var(F_w) = Var(F_{q-1, v_2})$$

Así, el estadístico F_W se asemeja a una distribución F_{q-1, v_2} .

A.2.2. Contrastes por parejas (t de Welch)

Para los contrastes a posteriori, no podemos usar el test t habitual, pues asume homocedasticidad. En su lugar, hemos de recurrir a un test t que base sus grados de libertad en las observaciones muestrales. Este es el caso del “Contraste para la comparación de medias de dos poblaciones normales independientes con varianzas desconocidas y distintas” presente en los apuntes de teoría de la asignatura: Contraste 4.8 del tema 4.

De manera similar al estadístico F_W , se basa en igualar momentos de variables aleatorias que no siguen distribuciones usuales para aproximarlas por otras que sí lo son.

B. Relación matemática entre la distribución Lognormal y la Normal

Sea X una variable aleatoria continua definida en el intervalo $(0, \infty)$. Se dice que X sigue una distribución lognormal con parámetros μ y σ , denotado como $X \sim \text{Lognormal}(\mu, \sigma^2)$, si su función de densidad de probabilidad viene dada por:

$$f_X(x) = \frac{1}{x\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right), \quad x > 0$$

Consideremos la transformación monótona creciente $Y = g(X) = \ln(X)$. Para determinar la distribución de la nueva variable aleatoria Y , aplicamos el método del cambio de variable para funciones de densidad.

La función inversa de la transformación es $X = g^{-1}(Y) = e^Y$. El soporte de la nueva variable Y es el conjunto de los números reales $\mathbb{R}$, dado que el logaritmo de un valor estrictamente positivo recorre todo el espectro real.

De acuerdo con el teorema del cambio de variable, la función de densidad de Y , denotada por $f_Y(y)$, se obtiene mediante la expresión:

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|$$

Sustituyendo los términos correspondientes:

1. $f_X(g^{-1}(y)) = f_X(e^y) = \frac{1}{e^y\sigma\sqrt{2\pi}} \exp\left(-\frac{(\ln(e^y) - \mu)^2}{2\sigma^2}\right) = \frac{1}{e^y\sigma\sqrt{2\pi}} \exp\left(-\frac{(y - \mu)^2}{2\sigma^2}\right)$
2. La derivada de la función inversa es $\frac{d}{dy} e^y = e^y$.

Al multiplicar ambos componentes, el término e^y se cancela en el numerador y el denominador:

$$f_Y(y) = \left[\frac{1}{e^y\sigma\sqrt{2\pi}} \exp\left(-\frac{(y - \mu)^2}{2\sigma^2}\right) \right] \cdot e^y$$

Resultando finalmente en:

$$f_Y(y) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y - \mu)^2}{2\sigma^2}\right), \quad y \in \mathbb{R}$$

La expresión obtenida para $f_Y(y)$ se identifica unívocamente con la función de densidad de una distribución normal de media μ y varianza σ^2 . Por tanto, queda demostrado que:

$$\text{Si } X \sim \text{Lognormal}(\mu, \sigma^2) \implies \ln(X) \sim \mathcal{N}(\mu, \sigma^2)$$

C. Código fuente y datos

Para garantizar la reproducibilidad completa del análisis estadístico expuesto en este informe y cumplir con las directrices de limpieza en la presentación, el código fuente completo implementado en lenguaje R ha sido empaquetado y se adjunta de manera independiente.

Dicho código fuente (que incluye la limpieza de los microdatos originales, la generación de todos los gráficos vectoriales, el ajuste de distribuciones paramétricas y la ejecución de los tests de homogeneidad y contrastes ANOVA/Wilcoxon), junto con el conjunto de datos de la Encuesta de Salud en España 2023, se encuentra disponible en el archivo comprimido **.zip** adjunto a la entrega principal de este trabajo.